

## 1.6 线性回归模型

CSDN学院  
2017年10月

## ► 线性回归

- 模型
  - 目标函数（损失函数、正则）
  - 概率解释
- 优化求解
- 模型选择

## ► 线性回归

- 给定训练数据  $\mathcal{D} = \{\mathbf{x}_i, y_i\}_{i=1}^N$  , 其中  $y \in \mathbb{R}$  , 回归学习一个从输入  $\mathbf{x}$  到输出  $y$  的映射  $f$
- 对新的测试数据  $\mathbf{x}$  , 用学习到的映射对其进行预测 :  $\hat{y} = f(\mathbf{x})$
- 若假设映射  $f$  是一个线性函数 , 即
$$y = f(\mathbf{x} | \mathbf{w}) = \mathbf{w}^T \mathbf{x}$$
- 我们称之为线性回归模型。

## ► 目标函数

- 目标函数通常包含两项：**损失函数**和**正则项**

$$J(\boldsymbol{\theta}) = \sum_{i=1}^N L(f(\mathbf{x}_i; \boldsymbol{\theta}), y_i) + \lambda \Omega(\boldsymbol{\theta})$$


- 对回归问题，损失函数可以采用L2损失，得到

$$\begin{aligned} J(\boldsymbol{\theta}) &= \sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 \end{aligned} \quad \text{残差平方和(residual sum of squares, RSS)}$$

## ► 线性回归的正则项

- 由于线性模型比较简单，实际应用中有时正则项为空，得到最小二乘线性回归（ Ordinary Least Square , OLS ）

$$\begin{aligned} J(\theta) &= \sum_{i=1}^N L(y_i, \hat{y}_i) = \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 \end{aligned}$$



## ► 线性回归的正则项

- 正则项可以为L2正则，得到岭回归（Ridge Regression）模型：

$$J(\mathbf{w}) = \underbrace{\sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2}_{\text{训练集上残差平方和}} + \underbrace{\lambda \|\mathbf{w}\|_2^2}_{\text{L2正则}}$$

- 正则项也可以选L1正则，得到Lasso模型：

$$J(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \lambda |\mathbf{w}|$$

- 当 $\lambda$ 取合适值时，Lasso（least absolute shrinkage and selection operator）的结果是稀疏的（ $\mathbf{w}$ 的某些元素系数为0），起到特征选择作用。

## ► 为什么 $L_1$ 正则的解是稀疏的?

- 考虑两个优化问题:


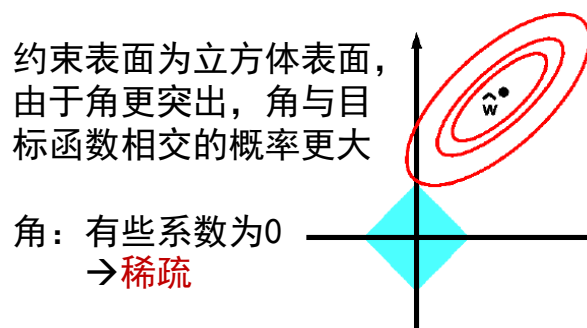
$$\min_{\mathbf{w}} \text{RSS}(\mathbf{w}) + \lambda \|\mathbf{w}\|_1$$

$$\min_{\mathbf{w}} \text{RSS}(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2$$

- 分别等价于 ( 连续的带约束的优化问题 )

$$\min_{\mathbf{w}} \text{RSS}(\mathbf{w}) \text{ s.t. } \|\mathbf{w}\|_1 \leq B$$

$$\min_{\mathbf{w}} \text{RSS}(\mathbf{w}) \text{ s.t. } \|\mathbf{w}\|_2^2 \leq B$$



- 例: 如  $\mathbf{w} = (1, 0)^T$ ,  $(1/\sqrt{2}, 1/\sqrt{2})^T$  的 $L_2$  模相同(1), 但 $L_1$ 模分别为1和 $\sqrt{2}$

## ► 线性回归模型的概率解释

- 最小二乘（线性）回归等价于极大似然估计
- 正则（线性）回归等价于高斯先验（L2正则）或Laplace先验下（L1正则）的贝叶斯估计



## ► 最小二乘线性回归 等价于 极大似然估计

- 假设： $y = f(\mathbf{x}) + \varepsilon = \mathbf{w}^T \mathbf{x} + \varepsilon$
- 其中 $\varepsilon$ 为线性预测和真值之间的残差
- 我们通常假设残差的分布为  $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ，因此线性回归可写成： $p(y | \mathbf{x}, \theta) \sim \mathcal{N}(y | \mathbf{w}^T \mathbf{x}, \sigma^2)$
- 其中  $\theta = (\mathbf{w}, \sigma^2)$

## ► Recall: 极大似然估计

- 极大似然估计 (Maximize Likelihood Estimator, MLE) 定义为

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} \log p(\mathcal{D} | \boldsymbol{\theta})$$

- 其中  $(\log)$  似然函数为

$$l(\boldsymbol{\theta}) = \log p(\mathcal{D} | \boldsymbol{\theta}) = \sum_{i=1}^N \log p(y_i | x_i, \boldsymbol{\theta})$$

- 表示在参数为 $\boldsymbol{\theta}$ 的情况下, 数据  $\mathcal{D} = \{\mathbf{x}_i, y_i\}_{i=1}^N$  出现的概率.
- 极大似然: 选择数据出现概率最大的参数。

## ► 线性回归的MLE

$$p(y_i | \mathbf{x}_i, \mathbf{w}, \sigma^2) = \mathcal{N}(y_i | \mathbf{w}^T \mathbf{x}_i, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} \left((y_i - \mathbf{w}^T \mathbf{x}_i)^2\right)\right)$$

- OLS的似然函数为

$$l(\boldsymbol{\theta}) = \log p(\mathcal{D} | \boldsymbol{\theta}) = \sum_{i=1}^N \log p(y_i | x_i, \boldsymbol{\theta})$$

- 极大似然可等价地写成极小负log似然损失(negative log likelihood , **NLL**)

$$NLL(\boldsymbol{\theta}) = -\sum_{i=1}^N \log p(y_i | x_i, \boldsymbol{\theta})$$

$$= -\sum_{i=1}^N \log \left[ \left( \frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp\left(-\frac{1}{2\sigma^2} \left((y_i - \mathbf{w}^T \mathbf{x}_i)^2\right)\right) \right]$$

$$= \frac{N}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2$$

## ► 正则回归等价于贝叶斯估计

- 假设残差的分布为  $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ，线性回归可写成：

$$p(y_i | \mathbf{x}_i, \boldsymbol{\theta}) \sim \mathcal{N}(y_i | \mathbf{w}^T \mathbf{x}_i, \sigma^2)$$

$$p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \sigma^2) = \mathcal{N}(\mathbf{y} | \mathbf{X}\mathbf{w}, \sigma^2 \mathbf{I}_N) \propto \exp\left(-\frac{1}{2\sigma^2} [(\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})]\right)$$

- 若假设参数 $\mathbf{w}$ 的先验分布为  $w_j \sim \mathcal{N}(0, \tau^2)$ 
  - 偏向较小的系数值，从而得到的曲线也比较平滑

$$p(\mathbf{w}) = \prod_{j=1}^D \mathcal{N}(w_j | 0, \tau^2) \propto \exp\left(-\frac{1}{2\tau^2} \sum_{j=1}^D w_j^2\right) = \exp\left(-\frac{1}{2\tau^2} [\mathbf{w}^T \mathbf{w}]\right)$$

- 其中  $1/\tau^2$  控制先验的强度

## ► 正则回归等价于贝叶斯估计


- 根据贝叶斯公式，得到参数的后验分布为

$$p(\mathbf{w} | \mathbf{X}, \mathbf{y}, \sigma^2) \propto \exp\left(-\frac{1}{2\sigma^2}[(\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})] - \frac{1}{2\tau^2}[\mathbf{w}^T \mathbf{w}]\right)$$

- 则最大后验估计（MAP）等价于最小目标函数

$$J(\mathbf{w}) = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w}) + \frac{\sigma^2}{\tau^2} \mathbf{w}^T \mathbf{w}$$

- 对比岭回归的目标函数


$$J(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2$$

## ► 小结

- 线性回归模型也可以放到机器学习一般框架
  - 损失函数：L2损失...
  - 正则：无正则、L2正则、L1正则...
- 正则回归模型可视为先验为正则、似然为高斯分布的贝叶斯估计