

CTR预估-GBDT

CSDN学院



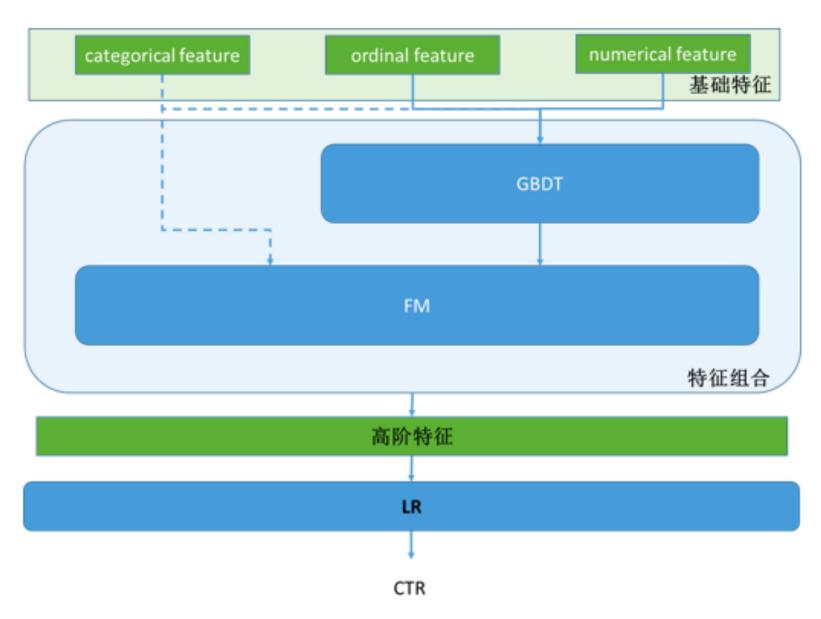
▶大纲



- CTR出现的背景
- Logistic回归 (LR)
- GBDT
- 因子分解机 (FM/FFM)
- 案例分析









Facebook : GBDT+LR



- Practical Lessons from Predicting Clicks on Ads at Facebook [1]
- 用GBDT编码特征,然后再用LR做分类
 - GBDT可替代FM做特征编码
 - LR可用FTRL代替

[1] Xinran He et al. Practical Lessons from Predicting Clicks on Ads at Facebook, 2014.

→动机



- 用LR做CTR预估时,需做大量的特征工程 →非线性特征
 - 连续特征离散化(+One-Hot编码)
 - 特征进行二阶或者三阶的特征组合
- 问题:
 - 连续变量切分点如何选取?
 - 离散化为多少份合理?
 - 选择哪些特征交叉?
 - 多少阶交叉,二阶,三阶或更多?
- GBDT:一举解决了上面的问题
 - 确定切分点和切分数目不在是凭主观经验,而是根据信息增益/Gini指标
 - 每棵决策树从根节点到叶节点的路径,会经过不同的特征,此路径就是特征组合,而且包含了二阶,三阶甚至更多(所以GBDT提取特征时层数不用太深)



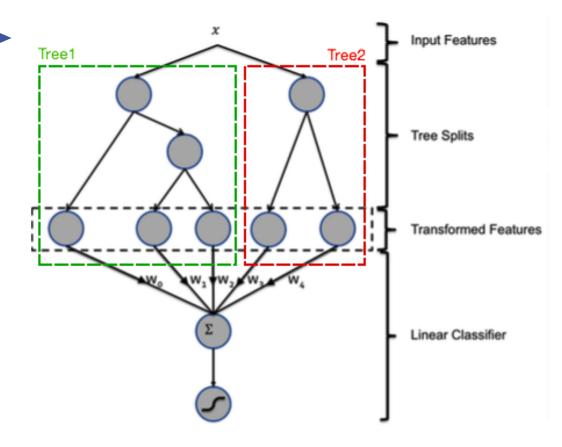


Figure 1: Hybrid model structure. Input features are transformed by means of boosted decision trees. The output of each individual tree is treated as a categorical input feature to a sparse linear classifier. Boosted decision trees prove to be very powerful feature transforms.



GBDT训练得到:

第一棵树有3个叶子结点

第二棵树有1个叶子节点

GBDT编码:对于一个输入样本点x,如果它在第一棵树最后落在其中的第3个叶子结点,在第二棵树里最后落在第1个叶子结点则通过GBDT获得的新特征向量为[0,0,1,0,1,0]

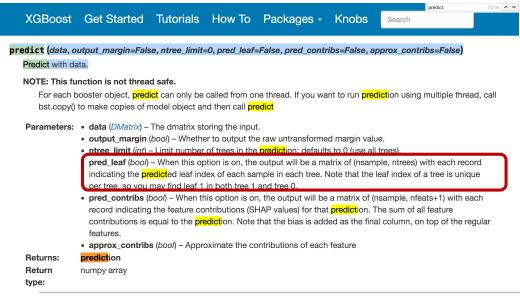
向量中的前三位对应第一棵树的3个叶子结点 后两位对应第二棵树的1个叶子结点



实现



- xgboost: predict函数
 - predict(data, output_margin=False, ntree_limit=0, pred_leaf=False, pred_contribs=False, approx_contribs=False)
- lightGBM: predict函数
 - predict(data, output_margin=False, ntree_limit=0, pred_leaf=False, pred_contribs=False, approx_contribs=False)





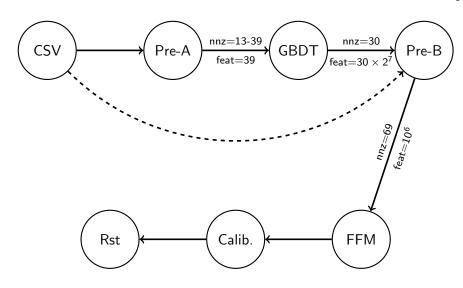
xgb_leaves = xgb_test_basis_d6.predict(dtv, pred_leaf = True)

► GBDT+FM





- Kaggle 2014年竞赛: Criteo Display Advertising Challenge
 - https://www.kaggle.com/c/criteo-display-ad-challenge
- Rank1解决方案:3 idiot's FM(FFM的发明者)



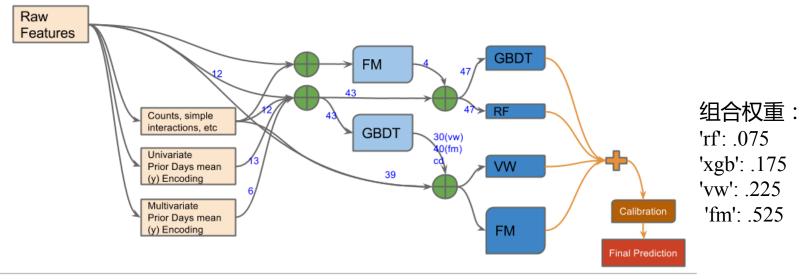


► GBDT+ FM & FM+GBDT





- Kaggle 2015年竞赛: Click-Through Rate Prediction
 - https://www.kaggle.com/c/avazu-ctr-prediction
- Rank2解决方案:





▶为什么不直接用GDBT?



- 因为GDBT在线预测比较困难,而且训练时间复杂度高于 LR。
- 所以实际中,可以离线训练GDBT,然后将该模型作为在 线ETL的一部分。





THANK YOU



