

4.10 聚类算法评估

CSDN学院
2017年11月

- 常用聚类算法
- 聚类性能评估
- 案例分析



- 聚类性能评价方法通常分为外部评价法 (external criterion) 和内部评价法 (internal criterion).
- 外部评价法分析聚类结果与另一参考结果 (reference, 如真实类别) 有多相近
 - Adjust Rand Index (ARI) , 互信息 (AMI) , V-measure、Fowlkes-Mallows scores
- 内部评价法来分析聚类的本质特点
 - Silhouette Coefficient , Calinski-Harabaz Index

- 假设有 N 个样本点，参考类别结果为 $C^* = \{c_1^*, \dots, c_L^*\}$
- C 为一个聚类结果， $C = \{c_1, \dots, c_K\}$
- 计算两个聚类结果 C 和参考类别结果 C^* 的样本点对的数目

$N_{11} = \#\{(\mathbf{x}_i, \mathbf{x}_j) | \mathbf{x}_i, \mathbf{x}_j \in C_k; \mathbf{x}_i, \mathbf{x}_j \in C_l^*\}$ C 与 C^* 中都是同类别的样本对数

$N_{00} = \#\{(\mathbf{x}_i, \mathbf{x}_j) | \mathbf{x}_i \in C_{k_1}, \mathbf{x}_j \in C_{k_2}; \mathbf{x}_i \in C_{l_1}^*, \mathbf{x}_j \in C_{l_2}^*\}$ C 与 C^* 中都是不同类别的样本对数

- **Rand指数**度量两个标签分配 C 和 C^* 的吻合程度，定义为：
$$R = \frac{n_{11} + n_{00}}{\binom{n}{2}}$$

$$RI = \frac{N_{11} + N_{00}}{\binom{N}{2}}$$

分母：集合中可以组成样本对的对数

$RI = 0$ 表明两种聚类没有重叠； $RI = 1$ 表示两个聚类完全相同

- 为了实现“在聚类结果随机产生的情况下，指标应该接近零”，Hubert and Arabie (1985)对 Rand index 进行了调整（减去随机类别结果的 RI 的期望 $E(RI)$ ），提出调整兰德系数（Adjusted Rand Index, ARI）：

$$ARI = \frac{RI - E(RI)}{\max(RI) - E(RI)}$$

- 取值范围为 $[-1, 1]$
 - 对两种独立的聚类值为 0, 两种完全相同的聚类值为 1
 - 值越大意味着聚类结果与真实情况越吻合

► 基于互信息的分数 (AMI)

C/C^*	C_1^*	...	C_L^*	sum
C_I	N_{II}	...	N_{IL}	a_I
...
C_K	N_{KI}	...	N_{KL}	a_K
sum	b_I	...	b_L	N

- AMI中用到的记号和ARI一样，只是将Rand指标换成互信息
- 回忆信息中关于熵 / 信息的定义：

- 令 N_{kl} 表示同时属于 C 中 C_k 和 C^* 中 C_l^* 的样本数目， $a_k = \sum_{l=1}^L N_{kl}$ 为 C 中 C_k 中的样本数目， $b_l = \sum_{k=1}^K N_{kl}$ 为 C^* 中 C_l^* 中的样本数目，则

$$H(C) = \sum_{k=1}^K p(k) \log p(k), \text{ where } p(k) = \frac{a_k}{N}$$

$$H(C^*) = \sum_{l=1}^L p'(l) \log p'(l), \text{ where } p'(l) = \frac{b_l}{N}$$

- C 和参考类别结果 C^* 之间的互信息定义为：

$$MI(C, C^*) = \sum_{k=1}^K \sum_{l=1}^L p(k, l) \log \frac{p(k, l)}{p(k)p'(l)}, \text{ where } p(k, l) = \frac{N_{kl}}{N}$$

- AMI对互信息的调整与ARI对RI的调整类似

$$AMI = \frac{MI - E(MI)}{\max(H(C), H(C^*)) - E(MI)}$$

C/C^*	C_1^*	...	C_L^*	sum
C_I	N_{I1}	...	N_{IL}	a_I
...
C_K	N_{KI}	...	N_{KL}	a_K
sum	b_I	...	b_L	N

- MI的期望为
$$E(MI) = \sum_{k=1}^K \sum_{l=1}^L \sum_{N_{ij}=(a_k+b_l-N)^+}^{\min(a_k, b_l)} \frac{N_{ij}}{N} \log \frac{N \times N_{kl}}{a_k b_l} \times \frac{a_k! b_l! (N - a_k)! (N - b_l)!}{N! N_{kl}! (a_k - N_{kl})! (b_l - N_{kl})! (N - a_k - b_l + N_{kl})!}$$
- AMI的取值范围为[0,1]
 - 对两种独立的聚类值为 0, 两种完全相同的聚类值为 1

Homogeneity, completeness and V-measure

C/C^*	C_1^*	...	C_L^*	sum
C_I	N_{II}	...	N_{IL}	a_I
...
C_K	N_{KI}	...	N_{KL}	a_K
sum	b_I	...	b_L	N

- 同质性 (homogeneity) : 一个簇是只包含一个类别的样本

$$h = 1 - \frac{H(C|C^*)}{H(C)}$$

- 其中 $H(C)$ 为聚类结果 C 的熵 :

$$H(C) = \sum_{k=1}^K p(C_k) \log p(C_k) = \sum_{k=1}^K \frac{N_k}{N} \log \frac{N_k}{N}$$

- $H(C/C^*)$ 为给定簇分配 C^* 条件下的类 C 的条件熵 :

$$H(C|C^*) = \sum_{k=1}^K \sum_{l=1}^L p(C_k, C_l^*) \log \frac{p(C_l^*)}{p(C_k, C_l^*)} = \sum_{k=1}^K \sum_{l=1}^L \frac{N_{kl}}{N} \log \frac{N_{kl}}{N_l}$$

Homogeneity, completeness and V-measure

C/C^*	C_1^*	...	C_L^*	sum
C_I	N_{II}	...	N_{IL}	a_I
...
C_K	N_{KI}	...	N_{KL}	a_K
sum	b_I	...	b_L	N

- 完整性 (completeness) : 同类别样本被归类到相同簇中

$$c = 1 - \frac{H(C^* | C)}{H(C^*)}$$

- V-measure为均一性和完整性的调和平均 :

$$v = 2 \frac{h \times c}{h + c}$$

► Fowlkes-Mallows scores

C/C^*	C_1^*	...	C_L^*	sum
C_I	N_{II}	...	N_{IL}	a_I
...
C_K	N_{KI}	...	N_{KL}	a_K
sum	b_I	...	b_L	N

- Fowlkes-Mallows score (FMI) 为成对精度 (precision) 和召回率 (recall) 的几何均值

- 精度 : $p = N_{kl} / a_k$

- 召回率 : $r = N_{kl} / b_l$

- $$FMI = \sqrt{p \times r} = \sqrt{\frac{N_{kl} \times N_{kl}}{a_k \times b_l}} = \frac{N_{kl}}{\sqrt{a_k \times b_l}}$$



- 聚类性能评价方法通常分为外部评价法 (external criterion) 和内部评价法 (internal criterion).
- 外部评价法分析聚类结果与另一参考结果 (reference, 如真实类别) 有多相近
 - Adjust Rand Index (ARI) , 互信息 (AMI) , V-measure、Fowlkes-Mallows scores
- 内部评价法来分析聚类的本质特点 , 又分为绝对评价和相对评价法 , 常用的方法有
 - Silhouette Coefficient , Calinski-Harabaz Index



► 轮廓系数 (Silhouette coefficient)

- 轮廓系数 (侧影法) 适用于实际类别信息未知的情况
- 对于其中的一个样本点 i , 记 :
 - $a(i)$: 样本点 i 到与其所属簇中其它点的平均距离
 - $\bar{d}(i, C)$: 样本点 i 到其他类 $C (C \neq C_i)$ 内所有点的平均距离
 - $b(i)$: 所有 $\bar{d}(i, C)$ 的最小值
- 则样本点 i 的轮廓系数为 : $s(i) = \frac{b(i) - a(i)}{\max \{a(i), b(i)\}}$

类内散度

类间散度

• 平均Silhouette值为 : $\bar{s} = \frac{1}{N} \sum_{i=1}^N s(i)$

- $-1 \leq s(i) \leq 1$ (当 $a(i) \ll b(i)$, $s(i)$ 接近 1)
 - 由 $a(i)$ 的定义可知：小的 $a(i)$ 意味着点 i 匹配该类非常好，而大的 $b(i)$ 意味着点 i 匹配其他类很差，从而 $s(i)$ 靠近 1 表明点 i 的聚类合适
- $s(i)$ 靠近 -1 表明点 i 被聚类到相邻类中更合适
- $s(i)$ 靠近 0 表明点 i 在两个类的交集处
- 可使用轮廓系数估计聚类中的类的数目
 - $\bar{s} > 0.5$ 表明聚类合适
 - $\bar{s} < 0.2$ 表明数据不存在聚类特征

► CH索引 (Calinski-Harabaz Index)

C/C^*	C_1^*	...	C_L^*	sum
C_I	N_{II}	...	N_{IL}	a_I
...
C_K	N_{KI}	...	N_{KL}	a_K
sum	b_I	...	b_L	N

- CH索引也适用于实际类别信息未知的情况
- 下面以 K -means算法为例，可推广到其他算法。

- 给定聚类数目 K ，类内散度为：
$$W(K) = \sum_{k=1}^K \sum_{C(j)=k} \|\mathbf{x}_j - \bar{\mathbf{x}}_k\|^2$$

- 类间散度：
$$B(K) = \sum_{k=1}^K a_k \|\bar{\mathbf{x}}_k - \bar{\mathbf{x}}\|^2$$

- 则CH索引为
$$CH(K) = \frac{B(K)(N-K)}{W(K)(K-1)}$$

计算快

THANK YOU



AI100