

线性空间

一、线性空间的定义

二、线性空间的基

三、线性空间的范数

线性空间的定义

设 V 是一个非空集合， R 为实数域。如果对于任意两个元素 $\alpha, \beta \in V$ ，总有唯一的元素 $\gamma \in V$ 与之对应，成为 α 和 β 的和，记为 $\gamma = \alpha + \beta$ ；又对于任一实数 $\lambda \in R$ 和任一元素 $\alpha \in V$ ，总有唯一的元素 $\delta \in V$ 与之对应，称为 λ 与 α 的积，记作 $\delta = \lambda\alpha$ ；并且这两种运算满足以下八条运算规律：

(设 $\alpha, \beta, \gamma \in V, \lambda, \mu \in R$)

$$(i) \alpha + \beta = \beta + \alpha$$

$$(ii) (\alpha + \beta) + \gamma = \alpha + (\beta + \gamma)$$

$$(iii) \text{在 } V \text{ 中存在零元素 } \theta \in V, \text{ 对任意的 } \alpha \in V, \text{ 都有 } \alpha + \theta = \alpha$$

$$(iv) \text{对于任何的 } \alpha \in V, \text{ 都有 } \alpha \text{ 的负元素 } \delta, \text{ 使得 } \alpha + \delta = \theta$$

$$(v) 1\alpha = \alpha$$

$$(vi) \lambda(\mu\alpha) = (\lambda\mu)\alpha$$

$$(vii) (\lambda + \mu)\alpha = \lambda\alpha + \mu\alpha$$

$$(viii) \lambda(\alpha + \beta) = \lambda\alpha + \lambda\beta$$

那么, 集合 V 就称为 (实数域上的) 线性空间 (或向量空间), 满足上述八条性质的加法和数乘运算, 称之为线性运算。

本质: 对于任意的 $\alpha, \beta \in V, \lambda, \mu \in R$, 都有 $\lambda\alpha + \mu\beta \in V$

例：设 $A_{m \times n}$ 是一个固定矩阵，则集合 $V = \{y \in R^m | y = Ax, x \in R^n\}$ 是线性空间

证明：（目标：任意 $y_1, y_2 \in V$, $a, b \in R$, 证明 $ay_1 + by_2 \in V$ ）

设 $y_1 = Ax_1, y_2 = Ax_2, x_1, x_2 \in R^n$

则 $ay_1 + by_2 = aAx_1 + bAx_2 = A(ax_1 + bx_2)$

由于 $x_1, x_2 \in R^n$, 所以 $x_3 = ax_1 + bx_2 \in R^n$

所以 $ay_1 + by_2 = Ax_3 \in V$ 。 所以， V 是一个线性空间

我们成这样的 V 为矩阵 A 的值域

例：设 $A_{m \times n}$ 是一个固定矩阵，则集合 $V = \{x \in R^n | Ax = 0\}$ 是线性空间

(目标：任意 $x_1, x_2 \in V$, $a, b \in R$, 证明 $ax_1 + bx_2 \in V$)

$$\begin{aligned}\text{证明：} \quad A(ax_1 + bx_2) &= A(ax_1) + A(bx_2) \\ &= aAx_1 + bAx_2 \\ &= a0 + b0 = 0\end{aligned}$$

我们成这样的 V 为矩阵 A 的核（方程组 $Ax=0$ 的解空间）

线性空间的基

线性表示： $\alpha_1, \alpha_2, \dots, \alpha_n, \beta \in V$, 若存在一组实数 $k_1, k_2, \dots, k_n \in R$, 满足

$$k_1\alpha_1 + k_2\alpha_2 + \dots + k_n\alpha_n = \beta, \quad \text{则称}\beta\text{可以由}\alpha_1, \alpha_2, \dots, \alpha_n\text{线性表示}$$

线性相关： $\alpha_1, \alpha_2, \dots, \alpha_n \in V$, 若存在一组不全为0的实数 k_1, k_2, \dots, k_n , 满足

$$k_1\alpha_1 + k_2\alpha_2 + \dots + k_n\alpha_n = \theta, \quad \text{则}\alpha_1, \alpha_2, \dots, \alpha_n\text{线性相关}$$

线性相关 \Leftrightarrow 至少存在一个向量可以被其余向量线性表示

线性无关： $\alpha_1, \alpha_2, \dots, \alpha_n \in V$, 若满足 $k_1\alpha_1 + k_2\alpha_2 + \dots + k_n\alpha_n = \theta$, 则必有

$$k_1 = k_2 = \dots = k_n = 0, \quad \text{则}\alpha_1, \alpha_2, \dots, \alpha_n\text{线性无关。}$$

例： 向量 $x_1 = (3,4), x_2 = (1,0), x_3 = (0,1)$, 我们有如下关系：

$$x_1 + (-3)x_2 + (-4)x_3 = (0,0)$$

所以 x_1, x_2, x_3 线性相关。

例： 证明向量 $x_1 = (3,4), x_2 = (1,0)$ 线性无关

证： 设 $k_1x_1 + k_2x_2 = \theta$ ，我们有

$$(3k_1, 4k_1) + (k_2, 0) = (0,0)$$

$$\begin{cases} 3k_1 + k_2 = 0 \\ 4k_1 = 0 \end{cases} \Rightarrow \begin{cases} k_1 = 0 \\ k_2 = 0 \end{cases}$$

所以， x_1, x_2 线性无关

线性空间基的定义

在线性空间 V 中，如果存在 n 个元素 $\alpha_1, \alpha_2, \dots, \alpha_n$ ，满足：

(i) $\alpha_1, \alpha_2, \dots, \alpha_n$ 线性无关

(ii) V 中任一元素 α 都可以由 $\alpha_1, \alpha_2, \dots, \alpha_n$ 线性表示

那么， $\alpha_1, \alpha_2, \dots, \alpha_n$ 称为线性空间 V 的一个基， n （基的个数）称为线性空间 V 的维数

空间 V 称为由基 $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 张成的线性空间，记作 $V = \text{span}\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 。

性质： $V = \{x \mid x = c_1\alpha_1 + c_2\alpha_2 + \dots + c_n\alpha_n, c_i \text{ 为任意实数}, i = 1, 2, \dots, n\}$

例：方程组 $Ax=0$ 的基础解系 $x_i (i = 1, \dots, n-r)$ 为其解空间的一组基

方程的解： $x = c_1x_1 + c_2x_2 + \dots + c_{n-r}x_{n-r}$ 其中 c_i 为任意实数



坐标： 若 V 是一个线性空间， $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 是线性空间 V 的一组基，对于 $\alpha \in V$ ，如果有 $\alpha = x_1\alpha_1 + x_2\alpha_2 + \dots + x_n\alpha_n$ ，那么其表示系数所构成的 n 为实向量 (x_1, x_2, \dots, x_n) 称为 α 在基 $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 下的坐标。所以，线性空间的元素称为向量

例： 二位实向量空间 $R^2 = \{(x, y) | x, y \in R\}$ 是一个线性空间，向量组 $\{(1, 0), (0, 1)\}$ ， $\{(1, 0), (1, 1)\}$ 分别都是 R^2 的一组基。向量 $(5, 3)$ 可以表示成 $(5, 3) = 5(1, 0) + 3(0, 1)$ 或者 $(5, 3) = 2(1, 0) + 3(1, 1)$ 。那么 $(5, 3)$ 在基 $\{(1, 0), (0, 1)\}$ 下的坐标是 $(5, 3)$ ，在基 $\{(1, 0), (1, 1)\}$ 下的坐标是 $(2, 3)$ 。

线性空间的范数（模）

在线性空间 V 中定义一种运算 $\|\cdot\|:V \rightarrow \mathbf{R}$, 对于任意的 $\alpha, \beta \in V$, $\lambda \in \mathbf{R}$ 满足如下性质：

(i) $\|\alpha\| \geq 0$, 若 $\|\alpha\|=0 \Leftrightarrow \alpha = \theta$ (零向量)

(ii) $\|\lambda\alpha\| = |\lambda|\|\alpha\|$

(iii) $\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$ (三角不等式)

则称 $\|\cdot\|$ 为线性空间 V 的一个范数，这样的 V 称为赋范线性空间。

赋范线性空间中的元素 $\alpha, \beta \in V$, 定义 $\|\alpha - \beta\|$ 为 α, β 之间的距离

例： n 维向量空间 R^n 是一线性空间，对于任意向量 $\mathbf{x} = (x_1, x_2, \dots, x_n) \in R^n$,

定义欧几里得范数 $\|\mathbf{x}\| = \sqrt{(x_1)^2 + (x_2)^2 + \dots + (x_n)^2}$

例：当 $1 \leq p < \infty$ 时，定义 R^n 空间的 L^p 范数如下：

$$\|\mathbf{x}\|_{L^p} (\|\mathbf{x}\|_p) = \left(\sum_i x_i^p \right)^{\frac{1}{p}}$$

当 $p = \infty$ 时， R^n 空间的 L^∞ 范数定义为 $\|\mathbf{x}\|_{L^\infty} (\|\mathbf{x}\|_\infty) = \max_i |x_i|$

在机器学习中，矩阵最常用的范数是Frobenius范数，定义如下：

$$\|A\|_F = \sqrt{\sum_{i,j} a_{i,j}^2}$$

矩阵分解

一、方阵的正交分解

二、矩阵的奇异值分解 (SVD)

三、应用举例：主成分分析 (PCA)

特征值与特征向量定义

定义： 设 $A_{n \times n}$ ，如果有数 λ_i 和 n 维非零列向量 x ，使

$$Ax = \lambda_i x \quad i=1,2,\dots,n$$

则称 λ_i 为 A 的特征值，非零列向量 x 为 A 的对应于特征值 λ_i 的特征向量

- 注：**
- (1) A 是方阵；
 - (2) 特征向量 x 是非零列向量；
 - (3) 属于每一个特征值 λ_i 的特征向量不唯一，有无数个
 - (4) 一个特征向量只能属于一个特征值。

特征值： λ_i 是关于 λ 的多项式 $|A - \lambda I_n| = 0$ 的根，记作 $\lambda_1, \lambda_2, \dots, \lambda_n$

特征向量：属于 λ_i 的特征向量是线性方程组 $(A - \lambda_i I_n)x = 0$ 的解

矩阵分解：

设 $\{x_{i1}, x_{i2}, \dots, x_{im}\}$ 是方程组 $(A - \lambda_i I_n)x = 0$ 解空间的基，定义矩阵

$P_{n \times n} = [x_{11}, x_{12}, \dots, x_{1m}, x_{21}, x_{22}, \dots]_{n \times n}$ 那么，我们可以把方阵A分解成

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_1 & \dots & 0 \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \lambda_n \end{bmatrix} \quad \text{或者} \quad A = P \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_1 & \dots & 0 \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \lambda_n \end{bmatrix} P^{-1}$$

我们称这样的分解为特征分解（相似对角化）

由 $P^{-1}AP = \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{pmatrix}$, 可以得到 $AP = P \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{pmatrix}$.

令 $P = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]$, 有

$$AP = A[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n] = [A\mathbf{x}_1, A\mathbf{x}_2, \dots, A\mathbf{x}_n] = (\lambda_1\mathbf{x}_1, \lambda_2\mathbf{x}_2, \dots, \lambda_n\mathbf{x}_n)$$

即

$$A\mathbf{x}_i = \lambda_i\mathbf{x}_i \quad (i = 1, 2, \dots, n)$$

可见, λ_i 是 A 的特征值, \mathbf{x}_i 为其特征值 λ_i 的特征向量.

正交矩阵：满足 $AA^T = I_n$ ($A^{-1} = A^T$)的 n 阶方阵称为正交矩阵

标准正交基： n 个 n 维向量 $\{x_1, x_2, \dots, x_n \in R^n\}$ ，若满足如下性质

$$\begin{cases} x_i x_j = 1 & \text{当 } i = j \text{ 时} \\ x_i x_j = 0 & \text{当 } i \neq j \text{ 时} \end{cases}$$

则称 $\{x_1, x_2, \dots, x_n \in R^n\}$ 为一组标准正交基

例： $\{(1,0,0), (0,1,0), (0,0,1)\}$ 为三维向量空间 R^3 的一组标准正交基

性质：若 $A=[x_1, x_2, \dots, x_n]$ 为 n 阶正交矩阵 $\Leftrightarrow \{x_1, x_2, \dots, x_n \in R^n\}$ 为一组标准正交基

正交矩阵的性质:

1、若A是正交矩阵， $\{x_1, x_2, \dots, x_n \in R^n\}$ 是一组标准正交基，那么

$\{Ax_1, Ax_2, \dots, Ax_n \in R^n\}$ 也是一组标准正交基

2、对直角坐标系做旋转变换，新旧坐标之间关系是一个正交变换，即存在一个正交矩阵A，使得原来坐标的点 $x = (x_1, x_2, \dots, x_n)$ 在新的坐标系下的坐标为 $y = Ax$

3、正交变换保持内积、长度、距离不变，即任意的n维向量 $x, y \in R^n$ ，有

内积不变 $(x, y) = (Ax, Ay)$

长度不变 $\|x\|_2 = \|Ax\|_2$ (取 $y = x$)

距离不变 $\|x - y\|_2 = \|Ax - Ay\|_2$ (取 $x = x - y$)

正交分解：

若 n 阶方阵 A 可进行特征分解（相似对角化），即存在 n 阶可逆矩阵 P ，使得

$$P^{-1}AP = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

其中 λ_i 为 A 的特征值， $P = [\mathbf{x}_{11}, \mathbf{x}_{12}, \dots, \mathbf{x}_{1m}, \mathbf{x}_{21}, \mathbf{x}_{22}, \dots]$ 列向量为 λ_i 对应的特征向量。

那么，一定存在另一组属于 λ_i 的特征向量 $Q = [\mathbf{y}_{11}, \mathbf{y}_{12}, \dots, \mathbf{y}_{1m}, \mathbf{y}_{21}, \mathbf{y}_{22}, \dots]$ ，满足向量组 $\{\mathbf{y}_{11}, \mathbf{y}_{12}, \dots, \mathbf{y}_{1m}, \mathbf{y}_{21}, \mathbf{y}_{22}, \dots\}$ 是一组 n 维标准正交基，即 Q 是 n 阶正交矩阵

$$Q^{-1}AQ = Q^T AQ = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

我们称该分解为正交分解。

注：正交分解是一种特殊的特征分解

正交分解的几何意义：

设 A 是一个实对称矩阵，即 $A^T = A$ ， $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 。称

$$f(x_1, x_2, \dots, x_n) = \mathbf{x}A\mathbf{x}^T$$

为二次型。

对矩阵 A 进行正交变换， $A = Q\Lambda Q^T$ 。那么 $f(\mathbf{x}) = \mathbf{x}Q\Lambda Q^T\mathbf{x}^T = (\mathbf{x}Q)\Lambda(\mathbf{x}Q)^T$

令 $\mathbf{x}Q = \mathbf{y} = (y_1, y_2, \dots, y_n)$ ，有 $f(\mathbf{x}) = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \dots + \lambda_n y_n^2$

正交变换的几何意义：把一般的二次曲线经过坐标旋转变成标准的二次曲线，
将其主轴（长轴、短轴）转到坐标轴上。

矩阵的SVD（奇异值分解）

非退化方阵的SVD：设 A 是 n 阶非退化方阵，即 $r(A) = n$ 。那么存在正交矩阵 P 和 Q ，使得

$$P^T A Q = \text{diag}(\alpha_1, \alpha_2, \dots, \alpha_n)$$

其中 $\alpha_i > 0$ ($i = 1, 2, \dots, n$)

- 1、不一定每个方阵都可以正交分解，只有实对称矩阵($A = A^T$)一定可以。但是每个方阵都可以有SVD
- 2、正交分解是同一个正交矩阵 Q ，SVD分解是两个正交矩阵 P 、 Q
- 3、正交分解对角线是特征值，SVD对角线不是特征值，但是都大于0

一般矩阵的SVD

设 A 是秩为 $r(r > 0)$ 的 $m \times n$ 阶实矩阵，则存在 m 阶正交矩阵 U 和 n 阶正交矩阵 V ，使得

$$U^T A V = \begin{bmatrix} \Lambda_r & 0_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{bmatrix}$$

其中 $\Lambda_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 为矩阵 A 的全部奇异值

$$A = U \begin{bmatrix} \Lambda & 0 \\ 0 & 0 \end{bmatrix} V^T = \sigma_1 U_1 V_1^T + \sigma_2 U_2 V_2^T + \dots + \sigma_r U_r V_r^T$$

U_i, V_i 为矩阵 U, V 的列向量。

Moore–Penrose伪逆:

设 $A \in R^{m \times n}$, 若 $A^+ \in R^{n \times m}$, 满足 :

$$AA^+A = A \quad A^+AA^+ = A^+$$

$$(AA^+)^T = AA^+ \quad (A^+A)^T = A^+A$$

则称 A^+ 为矩阵 A 的伪逆 , 上述四个方程称为Moore–Penrose方程。

不相容线性方程组的解

定义： 设 $A \in R^{m \times n}$, $b \in R^m$, $Ax = b$ 是不相容线性方程组。若存在向量 $x_0 \in R^n$

使得对于任何 $x \in R^n$, 都有 $\|Ax_0 - b\| \leq \|Ax - b\|$

则称 x_0 为方程组 $Ax = b$ 的最小二乘解

若 u 是方程组 $Ax = b$ 的最小二乘解, 如果对于任意一个最小二乘 x_0 , 都有

$$\|u\| \leq \|x_0\|$$

则称 u 是最佳最小二乘解。

定理： 设 $A \in R^{m \times n}$, $b \in R^m$, 则向量 $x = A^+ b$ 是方程组 $Ax = b$ 的最佳最小二乘解。

定理： 如果矩阵 A 的 SVD 为 $A = U\Lambda V^T$, 那么 A 的伪逆为 $A^+ = V\Lambda^+ U^T$, 其中 Λ^+ 是 Λ 的伪逆, 是将 Λ 主对角线上非零元素 σ_i 取倒数变成 $\frac{1}{\sigma_i}$ 之后再取转置



PCA（主成分分析）的数学原理

- 1、计算样品数据的协方差矩阵 $A = (s_{ij})_{n \times n}$ ，其中

$$s_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)$$

- 2、对矩阵 A 进行正交分解，并对特征值进行排序

$$Q^T A Q = \text{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0), \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$$

- 3、确定最小的 m ，使得贡献率 $G(m) = \frac{\sum_1^m \lambda_i}{\sum_1^r \lambda_i} > 85\%$

- 4、取 $F_i = Q_i x$ （ $i=1 \dots m$ ）为主成分变量，其中

$$x = (x_1, \dots, x_n)^T, Q_i \text{ 为正交矩阵 } Q \text{ 的第 } i \text{ 列向量}$$

THANK YOU



AI100